

# Tesina 2

## Analisi Algoritmo Genetico come Feature Selection su Dataset DARWIN

### Contesto del Problema

Un team di ricerca deve analizzare l'impatto dei diversi parametri degli Algoritmi Genetici (GA) sulla loro performance e convergenza utilizzando il dataset DARWIN. Questo dataset contiene caratteristiche di scrittura a mano per lo studio dell'Alzheimer, offrendo un contesto reale e significativo per l'analisi degli algoritmi genetici.

### Specifiche del Dataset

- DARWIN Dataset:
  - Features di scrittura a mano
  - Caratteristiche cinematiche
  - Pressione della penna
  - Parametri geometrici
  - Caratteristiche temporali
- Complessità:
  - Multiple feature categories
  - Dati numerici continui
  - Correlazioni complesse

### Obiettivi

1. Implementare un **Algoritmo Genetico** base per feature selection
2. Studiare sistematicamente l'effetto dei parametri:
  - Convergenza dell'algoritmo
  - Stabilità delle soluzioni
  - Velocità di esecuzione

- Robustezza della selezione
3. Determinare configurazioni ottimali per:
- Diverse dimensioni del subset di feature
  - Vincoli computazionali
  - Requisiti di stabilità

## **Vincoli**

- Utilizzo stesso seed per confronti equi
- Minimo 30 run per configurazione
- Tempo massimo di esecuzione per run
- Gestione appropriata missing values

## **Fasi del Progetto**

### **Fase 1: Implementazione GA Base**

- Sviluppare algoritmo genetico con:
  - Codifica binaria per selezione feature
  - Funzione fitness basata su correlation analysis
  - Operatori genetici modulari
- Implementare logging dettagliato:
  - Fitness per generazione
  - Feature selezionate
  - Tempi di esecuzione
  - Diversità popolazione

### **Fase 2: Analisi Parametrica**

#### **1. Scenario Dimensione Popolazione**

- Test dimensioni: [20, 50, 100, 200, 500]
- Metriche:
  - Velocità convergenza

- Stabilità selezione feature
- Costo computazionale
- Altri parametri fissi:
  - Crossover: 0.8
  - Mutazione: 0.1

## 2. Scenario Operatori Genetici

- Crossover rates: [0.6, 0.7, 0.8, 0.9]
- Mutation rates: [0.01, 0.05, 0.1, 0.15]
- Metodi selezione:
  - Tournament (k=2,3,4)
  - Roulette Wheel
- Popolazione fissa: 100

## 3. Scenario Criteri di Stop

- Numero generazioni fisse: [50,100,200]
- Convergenza (no improvement):
  - Soglie: [10,20,30] generazioni
  - Tolleranze: [1e-4, 1e-5, 1e-6]

## Output Richiesti per Ogni Scenario

- Curve di convergenza
- Box plot distribuzioni fitness
- Frequenza selezione feature
- Tempi di esecuzione